

Содержание

Введение.....	2
Математическое ожидание.....	2
Дисперсия и среднее квадратическое отклонение	3
Корреляция	6
Практическая часть	9
Дисперсия и среднее квадратическое отклонение	9
Корреляция	17
Вывод.....	25
Список литературы	26

Введение

Математическое ожидание

Накапливая данные, мы получили совокупность, состоящую из n исходов, пусть n_i – число исходов i -го типа. Отсюда $\sum_i n_i = n$. Допустим далее, что X_i – значение исхода i -го типа. Тогда среднее значение принимает вид:

$$X_{\text{ср}} = \frac{1}{n} \sum n_i x_i = \bar{X} \quad (1)$$

В данном случае среднее является некоторой величиной, полученной наблюдением. Теперь нам необходимо предсказать среднее значение. Прогнозируемое среднее значение случайной величины X называется математическим ожиданием. Если случайная величина X может принимать значения X_1, X_2, \dots, X_i с вероятностями P_1, P_2, \dots, P_i , то средним значением величины X , то есть математическим ожиданием (обозначают МОЖ, МО или М), будет:

$$M(\bar{X}) = \sum_{i=1}^n P_i X_i \quad (2)$$

Математическое ожидание является абстрактным понятием. Однако, когда n велико, среднее значение \bar{X} и $M(\bar{X})$ по существу оказываются численно равными.

Рассмотрим такой пример: в цехе на 4 станках изготавливают одинаковые детали. За месяц на первом станке изготовлено 100 деталей, из них вероятность первого сорта 0,9, на втором – 150 деталей с вероятностью первого сорта 0,8, на третьем – 100 деталей с вероятностью первого сорта 0,95, и на четвертом – 120 деталей с вероятностью первого сорта 0,75. Найти $M(\bar{X})$ общего числа деталей первого сорта, изготовленных на четырех станках.

Следует сразу заметить, что изготовление деталей первого сорта есть величина случайная, следовательно искомое

$$M(\bar{X}) = M(\bar{X}_1) + M(\bar{X}_2) + M(\bar{X}_3) + M(\bar{X}_4) = 100 * 0,9 + 150 * 0,8 + 100 * 0,95 + 120 * 0,75 = 395 \text{ деталей.}$$

Рассмотрим пример другого рода. Пусть независимые случайные величины X и Y заданы:

Таблица 1

X	10	3	6	2
P_x	0,2	0,3	0,1	0,4

Y	15	10	20
P_y	0,2	0,7	0,1

Найти $M(\bar{X})$ случайной величины XY .

Для нахождения воспользуемся (1):

$$M(\bar{X}) = 10 * 0,2 + 3 * 0,3 + 6 * 0,1 + 2 * 0,4 = 4,3$$

$$M(\bar{Y}) = 15 * 0,2 + 10 * 0,7 + 20 * 0,1 = 12$$

Так как случайные величины X и Y независимы, то искомое $M(X, Y)$

$$M(X, Y) = M(\bar{X}) * M(\bar{Y}) = 12 * 4,3 = 51,6$$

Дисперсия и среднее квадратическое отклонение

Среднее значение не всегда может характеризовать действительную картину учитываемых величин.

Рассмотрим две группы величин:

$$1: \{0,48; 0,49; 0,50; 0,50; 0,53\} \quad \bar{1} = 0,5$$

$$2: \{0,20; 0,30; 0,50; 0,60; 0,90\} \quad \bar{2} = 0,5$$

Как характеризовать данный разброс величин?

Величина, называемая дисперсией, используется как характеристика разброса или ожидаемого разброса. Дисперсия совокупности имеет вид:

$$D^2(X) = \frac{1}{n} \sum_i n_i (X - M)^2 \quad (3)$$

Прогнозируемая дисперсия:

$$D^2(X) = \sum_i P_i (X - M)^2 \quad (4)$$

Рассмотрим приведенные выше группы: $P_i = \frac{1}{5} = 0,2$

$$M(X_1) = 0,48 * 0,2 + 0,49 * 0,2 + 0,5 * 0,2 + 0,5 * 0,2 + 0,53 * 0,2 = 0,5$$

$$M(X_2) = 0,2 * 0,2 + 0,3 * 0,2 + 0,5 * 0,2 + 0,6 * 0,2 + 0,9 * 0,2 = 0,5$$

Исходов для групп:

Таблица 2

I группа		II группа	
$(0,48-0,5)^2$	0,0004	$(0,2-0,5)^2$	0,09
$(0,49-0,5)^2$	0,0001	$(0,3-0,5)^2$	0,04
$(0,5-0,5)^2$	0	$(0,5-0,5)^2$	0
$(0,5-0,5)^2$	0	$(0,6-0,5)^2$	0,01
$(0,53-0,5)^2$	0,0009	$(0,9-0,5)^2$	0,16
Итого	0,0014	Итого	0,3
D^2	0,00028	D^2	0,06

Чтобы понять смысл дисперсии, заметим, что для I группы, значения данных которой мало отличаются друг от друга, дисперсия равна 0,00028, в то же время для II группы, характеризующейся значительным разбросом, дисперсия равна 0,06. Среднее квадратическое отклонение, которое является просто квадратным корнем из дисперсии, употребляется чаще, чем дисперсия и имеет ту же размерность, что и среднее значение. В нашем примере, среднее квадратическое отклонение для I группы данных – 0,017. Это показывает, что большая часть данных лежит в интервале $0,5 \pm 0,017$, тогда как для второй группы среднее квадратическое отклонение равно $0,5 \pm 0,245$. Часто необходимо использовать оценку числа исходов n или оценку вероятностей P для вычисления средних значений и средних квадратических отклонений, но не менее важно уметь решать обратную задачу. Если известны средние значения и средние квадратические отклонения, то какова вероятность появления каждого i -го события?

Рассмотрим такой пример. Завод выпускает станки 4 типов стоимостью 7, 9, 11 и 15 тысяч рублей. Количество станков неизвестно, но известно, что средняя стоимость станка составляет 9 тысяч рублей. Какова оценка распределения станков по типам является лучшей (Потребность в каждом станке будем считать одинаковой)? Обратная задача такого типа имеет бесконечное множество решений, удовлетворяющих среднему значению. Какое же решение является оптимальным? Чтобы ответить на этот вопрос и решить пример, нужно напомнить одно из положений теории информации.

Неопределенность результата события возрастает с увеличением числа равновероятных исходов. Следовательно, должно возрастать количество информации в сообщении о результате. Величина, определяющая количественную меру неопределенности исхода события, называется энтропией события (H).

$$H = - \sum_{i=1}^n P_i \log_2 P_i,$$

где P – вероятность, i – исход события, n – число всех возможных

Если новый станок с ЧПУ дает не более 5% брака, то следовательно, вероятность изготовления годных деталей на нем $P_r = 0,95$, а бракованных $P_6 = 0,05$. Энтропия этого станка

$$H = 0,95 * \log_2 \frac{1}{0,95} + 0,05 * \log_2 \frac{1}{0,05} = 0,29$$

Для изношенного станка появление годных и бракованных деталей становится одинаково вероятным, неопределенность достигает наибольшего значения $P_r = P_6 = 0,5$ и энтропия достигает максимального значения для события с двумя исходами:

$$H = 0,5 * \log_2 \frac{1}{0,5} + 0,5 * \log_2 \frac{1}{0,5} = 1$$

С помощью этой формулы можно подсчитать количество информации. Единица информации содержит в себе какое-либо законченное сообщение. Эту единицу информации называют бит – бинарная или двойная единица. Используя формулу (H) для нашего конкретного примера, наименее смещенную оценку, максимизируя функцию $H = - \sum_{i=1}^n P_i \log_2 P_i$, при заданных ограничениях. В данном случае ограничениями являются $\sum_i P_i = 1$ и $\sum_i P_i n = \bar{n} = 9000$. Функция H – средняя неопределенность информации о системе. Чтобы максимизировать функцию H , обычно используют множители Лагранжа. Для нахождения ее оптимального значения продифференцируем функцию H и результат приравняем нулю. Затем продифференцируем уравнения для ограничивающих условий и умножим каждое из них на множитель Лагранжа (множители Лагранжа λ и β пока еще неизвестны, при чем они различны для различных уравнений).

$$\alpha_n = \sum_i (\ln P_i + 1) \alpha P_i = 0$$

$$\lambda \sum_i \alpha P_i = 0$$

$$\beta \sum_i n_i \alpha P_i = 0$$

Суммируя эти выражения, и замечая, что $\alpha P_i = 0$, получим

$$\sum_i (\ln P_i + \lambda + \beta n_i) \alpha P_i = 0,$$

где $P_i = \exp(-\lambda - \beta n_i)$

Множители Лагранжа λ и β найдем путём использования двух исходных уравнений для ограничений.

$$\lambda = \ln \left[\sum_i \exp(-\beta n_i) \right]$$
$$n = \frac{\sum_i n_i \exp(-\beta n_i)}{\sum_i \exp(-\beta n_i)}$$

Следовательно, $P_i = \exp(-\lambda - \beta) = \frac{\exp(-\beta n_i)}{\sum_i \exp(-\beta n_i)}$

Для нашего примера имеем:

$$\bar{n} = \frac{\sum_i n_i \exp(-\beta n_i)}{\sum_i \exp(-\beta n_i)} = \frac{7x^2 + 9x^9 + 11x^{11} + 15x^{15}}{x^7 + x^9 + x^{11} + x^{15}} = 9$$

Где $x = \exp(-\beta)$, а значения n взяты в тысячах. После преобразований

$$6x^{15} + 2x^{11} - 2x^7 = 0$$

Корень $x = 0$ не имеет смысла, то $6x^8 + 2x^4 - 2 = 0$, решая квадратное уравнение получим, что $x = 0,81177$.

Определим вероятности: $P_i = \frac{x^{n_i}}{\sum_i x^{n_i}}$

$$P_1 = \frac{0,809^7}{0,809^7 + 0,809^9 + 0,809^{11} + 0,809^{15}} = 0,438$$

$$P_2 = 0,289, \quad P_3 = 0,19, \quad P_4 = 0,083$$

Таким образом, наилучшей оценкой, которую можно сделать на основании имеющейся информации, является следующая: 44% станков стоят по 7 тысяч рублей, 29% - по 9, 19% - по 11 и 8% - по 15.

Корреляция

Огромная ценность теории вероятности и математической статистики заключается в том, что они позволяют выразить количественно неопределенность или субъективные ощущения. На диаграмме 1 изображены два графика. На глаз кажется, что величины u и v связаны между собой в большей степени, чем величины x и y . Часто полезно иметь количественный

показатель так называемой «корреляции». Для этой цели в математической статистике введен параметр, называемый коэффициентом корреляции r . Его выбирают таким образом, чтобы в случае, когда зависимость между рассматриваемыми переменными выражается прямой линией, значение r было равно 1. Когда эти величины совершенно случайны, коэффициент корреляции равен 0.




Диаграмма 1

Чтобы получить коэффициент r между двумя случайными величинами, необходимо для каждой из них вычислить среднее значение и среднее квадратическое отклонение. Для величин u и v в таблице 3 среднее значение и среднее квадратическое отклонение рассчитываются по формулам:

$$\bar{u} = \frac{1}{n} \sum_{i=1}^n u_i \quad \sigma_u = \sqrt{\frac{\sum (u_i - \bar{u})^2}{n-1}}$$

Таблица 3

1	4	1	4
5	2	2	1
7	8	2	6
2	5	4	8
9	5	3	1
8	10	5	10
8	12	7	2
10	15	8	15
12	12	10	18
12	16	10	5
15	17	12	12
4	6	14	7
3	3	9	9
6	10	13	10
14	18	6	7
u = 7,73	v = 9,53	x = 7,07	y = 7,67

В данном случае коэффициент корреляции равен:

$$r = \frac{\sum_i^n (u_i - \bar{u})(v_i - \bar{v})}{(n - 1)\sigma_u\sigma_v}$$

Для данных значений $r = 0.84$, что указывает на наличие сильной корреляции, тогда как для второй серии данных коэффициент корреляции составил 0.47. Однако к данному показателю следует относиться очень осторожно. Если между двумя величинами существует корреляция, то это еще не означает, что они связаны друг с другом как причина и следствие.

Практическая часть

Дисперсия и среднее квадратическое отклонение

Для закрепления знаний по понятиям математической статистике и заданием было выбрана разработка программы для обработки результатов измерений и подсчетов математических ожиданий, дисперсии и среднего квадратического отклонения. Программа была реализована на языке программирования C++ и имеет следующий функционал:

- Ввод результатов измерений через консоль;
- Ввод результатов измерений из оформленного файла input.txt;
- Подсчет математического ожидания для введенных данных для количества исходов и их значений;
- Подсчет математического ожидания для введенных данных для вероятности исхода и его значения;
- Подсчет дисперсии системы для разных вариантов данных;
- Вывод переданных данных, вместе с их обработкой, математическим ожиданием, дисперсией и средним квадратическим отклонением.

Рассмотрим заголовочный файл программы lib.h:

```
#ifndef LIB_H
```

```
#define LIB_H
```

```
class base {
```

```
public:
```

```
    void input();
```

```
    void finput();
```

```
    void me_count();
```

```
    void ma_count();
```

```
    void de_count();
```

```
    void da_count();
```

```
    void output();
```

```
private:
```

```
    double *data[3];
```

```

    int size;

    double average;

    double dis;

};

class application : public base {

public:

    void init();

    void exec();

private:

    bool choice;

};

#endif

```

В рассматриваемом файле описывается базовый класс base, который хранит массив из трех ссылок на тип double, которые будут использоваться для хранения и обработки информации, переменную size, хранящий количество исходов, average хранит математическое ожидание для хранящихся данных, dis хранит дисперсию хранящихся данных. В классе base описаны следующие методы:

- input() производит чтение данных из консоли;
- finput() производит чтение данных из файла input.txt;
- me_count() производит подсчет математического ожидания величины, при заданных параметрах вероятности исхода и его величины;
- ma_count() производит подсчет математического ожидания величины, при известном количестве исходов разных типов и их величин;
- de_count() рассчитывает дисперсию при данных вероятностях;
- da_count() рассчитывает дисперсию при данных о количестве исходов разных типов;
- output() производит вывод в консоль и файл output.txt о рассчитанных данных о квадратичном отклонении каждого исхода, о математическом ожидании для данных сведений, дисперсии и среднем квадратичном отклонении.

Класс application является наследником класса base и имеет одно свойство choice, хранящее в себе значение выбора обработки данных и два метода:

- init(), который заполняет объект данными;
- exes(), который выполняет подсчеты и выводит данные.

Внизу представлен файл реализации lib.cpp:

```
#include "lib.h"

#include <cmath>

#include <fstream>

#include <iostream>

using namespace std;

void base::input() {

    cout << "Введите количество пар значений" << endl;

    cin >> size;

    data[0] = new double[size];

    data[1] = new double[size];

    data[2] = new double[size];

    cout << "Введите " << size << " пар элементов через пробел" << endl;

    for (int i = 1; i <= size; i++) {

        cout << "Введите " << i << " пару элементов ";

        cin >> data[i - 1][0] >> data[i - 1][1];

    }

}

void base::finput() {

    fstream file("input.txt", ios::in);

    file >> size;

    data[0] = new double[size];

    data[1] = new double[size];

    data[2] = new double[size];
```

```

    for (int i = 0; i < size; i++) {
        file >> data[0][i] >> data[1][i];
    }
    file.close();
}

void base::ma_count() {
    average = 0.0;
    int n = 0;
    for (int i = 0; i < size; i++) {
        average += data[0][i] * data[1][i];
        n += (int)data[0][i];
    }
    average /= n;
}

void base::me_count() {
    average = 0.0;
    for (int i = 0; i < size; i++) {
        average += data[0][i] * data[1][i];
    }
}

void base::da_count() {
    dis = 0.0;
    int n = 0;
    ma_count();
    for (int i = 0; i < size; i++) {
        data[2][i] = data[0][i] * (data[1][i] - average) * (data[1][i] - average);
        dis += data[2][i];
    }
}

```

```

        n += data[0][i];
    }
    dis /= n;
}

void base::de_count() {
    dis = 0.0;
    me_count();
    for (int i = 0; i < size; i++) {
        data[2][i] = data[0][i] * (data[1][i] - average) * (data[1][i] - average);
        dis += data[2][i];
    }
}

void base::output() {
    fstream file("output.txt", ios::out);
    for (int i = 0; i < size; i++) {
        for (int j = 0; j < 3; j++) {
            cout.width(15);
            cout << data[j][i];
            file.width(15);
            file << data[j][i];
            if (j == 2) {
                file << endl;
                cout << endl;
            }
        }
    }

    cout << "Математическое ожидание для данного множества:  $M(X) =$ " <<
average

```

```

        << endl;

        cout << "Дисперсия для данного множества:  $D^2 =$  " << dis << endl;
        cout << "Среднеквадратическое отклонение:  $\sqrt{D^2} =$  " << sqrt(dis);

        file << "Математическое ожидание для данного множества:  $M(X) =$  " <<
average
        << endl;

        file << "Дисперсия для данного множества:  $D^2 =$  " << dis << endl;
        file << "Среднеквадратическое отклонение:  $\sqrt{D^2} =$  " << sqrt(dis);
        file.close();
    }

    void application::init() {
        cout << "Хотите вводить данные вручную или из файла (0 и 1,
соответственно)"
        << endl;

        int ch;
        cin >> ch;

        if (ch) {
            finput();
        } else {
            input();
        }
    }

    void application::exec() {
        cout << "Хотите посчитать для количества исходов или их вероятностей
(0 и 1 "
        "соответственно)"
        << endl;

        cin >> choice;

        if (choice) {

```

```

    de_count();
} else {
    da_count();
}
output();
}

```

Ниже представлен файл основной программы main.cpp:

```

#include "lib.h"
#include <iostream>

```

```

int main() {
    application app;
    app.init();
    app.exec();
    return 0;
}

```

Для тестирования данной программы были использованы следующие данные input.txt:

```

5
1 0.48
1 0.49
1 0.50
1 0.50
1 0.53

```

В результате работы программы в файле output.txt было следующее:

1	0.48	0.0004
1	0.49	0.0001
1	0.5	0

1	0.5	0
1	0.53	0.0009

Математическое ожидание для данного множества: $M(X) = 0.5$

Дисперсия для данного множества: $D^2 = 0.00028$

Среднеквадратическое отклонение: $\sqrt{D^2} = 0.0167332$

Возвращаясь к примеру из теоретического введения, убеждаемся, что программа действительно работает правильно.

Для второго теста использовались значения вероятностей исходов, содержание input.txt:

```
5
0.2 0.2
0.2 0.3
0.2 0.5
0.2 0.6
0.2 0.9
```

В результате работы программы в файле output.txt было следующее:

0.2	0.2	0.018
0.2	0.3	0.008
0.2	0.5	0
0.2	0.6	0.002
0.2	0.9	0.032

Математическое ожидание для данного множества: $M(X) = 0.5$

Дисперсия для данного множества: $D^2 = 0.06$

Среднеквадратическое отклонение: $\sqrt{D^2} = 0.244949$

Сопоставляя с примером из теоретического введения, убеждаемся в корректной работе программы.

Корреляция

Следующая программа, реализованная на языке программирования C++, обладает следующей функциональностью:

- Ввод информации из текстового файла input.txt;
- Вывод в текстовый файл output.txt;
- Подсчет среднего квадратического отклонения и среднего значение, а также коэффициента корреляции.

Рассмотрим заголовочный файл программы lib.h:

```
#ifndef LIB_H
```

```
#define LIB_H
```

```
class data_base {
```

```
private:
```

```
    double **p_double;
```

```
    double adis, bdis, corel;
```

```
    double aver_a = 0.0, aver_b = 0.0;
```

```
    int n;
```

```
public:
```

```
    bool ready = true;
```

```
    void input();
```

```
    void count();
```

```

    void output();

};

class application : public data_base {

public:

    void init();

    void exec();

};

#endif

```

Как видно из заголовочного файла программа реализована в объектно-ориентированном стиле, при этом имеется базовый класс `data_base`, со свойствами `double **p_double`, с помощью которого будет выделяться память и осуществляться доступ к вводимым данным, `adis` и `bdis`, хранящие средние квадратические отклонения, `aver_a` и `aver_b`, хранящие средние значения, целочисленной `n`, хранящее размер вводимых данных и булево значение `ready`, со следующими методами:

- `input()`, осуществляющий ввод из файла `input.txt`;
- `count()`, осуществляющий все необходимые расчёты;
- `output()`, реализующий вывод данных из программы в файл `output.txt`;

Реализован также дочерний класс `application` с методами:

- `init()`, обрабатывающий ввод данных;
- `exec()`, который инициализирует подсчеты и вывод данных в файл.

Внизу представлен файл реализации `lib.cpp`:

```

#include "lib.h"

```

```

#include <cmath>

#include <fstream>

#include <iostream>

using namespace std;


void application::init() {

    cout << "Готов ли файл input.txt к обработке? Если нет введите 0, если
да, "

        "то 1"

    << endl;

    int choice;

    cin >> choice;

    if (choice) {

        input();

    } else {

        ready = 0;

        return;

    }

}

void application::exec() {

    if (ready) {

```

```

        count();

        output();

    }

}

void data_base::input() {

    fstream file;

    file.open("input.txt", ios::in);

    file >> n;

    p_double = new double *[2];

    p_double[0] = new double[n];

    p_double[1] = new double[n];

    for (int i = 0; i < n; i++) {

        file >> p_double[0][i] >> p_double[1][i];

    }

    file.close();

}

void data_base::count() {

    double summ = 0.0;

    for (int i = 0; i < n; i++) {

        aver_a += p_double[0][i];

```

```

    aver_b += p_double[1][i];

}

aver_a /= n;

aver_b /= n;

double a, b;

for (int i = 0; i < n; i++) {

    a = p_double[0][i] - aver_a;

    b = p_double[1][i] - aver_b;

    summ += a * b;

    adis += a * a;

    bdis += b * b;

}

adis = sqrt(adis / (n - 1));

bdis = sqrt(bdis / (n - 1));

summ = summ / (n - 1);

corel = summ / (adis * bdis);

}

void data_base::output() {

    fstream file;

    file.open("output.txt", ios::out);

    for (int i = 0; i < n; i++) {

```

```

    file.width(15);

    file << p_double[0][i];

    file.width(15);

    file << p_double[1][i] << endl;

}

file << "Среднеквадратическое отклонение для первой величины: " <<
adis

    << endl;

file << "Среднее для первой величины: " << aver_a << endl;

file << "Среднеквадратическое отклонение для второй величины: " <<
bdis

    << endl;

file << "Среднее для второй величины: " << aver_b << endl;

file << "Коэффициент корреляции: " << corel << endl;

file.close();

delete[] p_double[0];

delete[] p_double[1];

delete[] p_double;

}

```

Далее предоставлен файл prog.cpp:

```

#include "lib.h"

#include <iostream>

```

```
using namespace std;
```

```
int main() {  
  
    application app;  
  
    app.init();  
  
    app.exec();  
  
    return 0;  
  
}
```

Программа была испытана на компьютере с операционной системой Ubuntu 18.04 с набором компиляции GCC. В файле input.txt находились следующие данные:

15

1 4

5 2

7 8

2 5

9 5

8 10

8 12

10 15

12 12

12 16

15 17

4 6

3 3

6 10

14 18

В результате работы программы в файле output.txt оказалось следующее:

1 4

5 2

7 8

2 5

9 5

8 10

8 12

10 15

12 12

12 16

15 17

4 6

3 3

6 10

14 18

Среднеквадратическое отклонение для первой величины: 4.31719

Среднее для первой величины: 7.73333

Среднеквадратическое отклонение для второй величины: 5.33006

Среднее для второй величины: 9.53333

Коэффициент корреляции: 0.872673

Обращаясь к разобранному во введении примеру можем убедиться в корректности работы программы.

Вывод

Изучил такие понятия математической статистики как математическое ожидание, дисперсия, среднее квадратическое отклонение, энтропия системы и процесса, ознакомился с поиском оптимального решения задачи на распределение путем множителей Лагранжа, изучил понятие корреляции и его приложение к количественному описанию неопределенности. Закрепил полученные знания путем написания программы для обработки данных и соответствующего расчета математического ожидания, дисперсии и среднего квадратического значения, а также реализацией программы для подсчета корреляции двух параметров.

Список литературы

1. **Михайлович, Тарасевич Олег.** Методы оптимизации и анализ процессов в технологии машиностроения. Москва : Редакционно-издательский отдел, 1976 г.